Stage en analyse de données et Machine Learning

Mouhamed Nourou Dine Cisse

ENSIIE / Bangath Systems & Gainde 2k

October 7, 2025

Introduction et Environnement de stage

Bangath Systems

- Spécialisée en en valorisation de données.
- Partenariat avec Gaïndé 2000 (Douane, Port Autonome de Dakar, DP World)

Département Data Science & IA

- Collecte et nettoyage des données
- Conception de modèles prédictifs
- Intégration via Oracle APEX et JupyterLab (Oracle Cloud)

Contexte du stage

- Gaïndé 2000 : acteur majeur de la dématérialisation douanière
- Important patrimoine de données portuaires (plateforme Orbus Infinity)
- IA = enjeu stratégique pour valoriser ces données

Objectif du stage

- Analyser et valoriser les données portuaires
- Construire et évaluer des modèles prédictifs
- Implémenter les modèles sous Python (Oracle Cloud)
- Fournir un prototype/méthodologie intégrable à la plateforme

Contributions majeures

- Modèle de classification (Random Forest) avec un **F1-score de 0.99**
- Prévision de volumes (conteneurs, poids, colis) via ARIMA, SARIMA, Random Forest, **MAE de 0.36**
- Estimer le flux quotidien de dossiers afin d'optimiser la planification des ressources humaines avec un **MAE de 0.70**.
- Pipeline reproductible et intégré à l'infrastructure Oracle

Organisation et collaboration

- Points quotidiens avec l'équipe Bangath Systems
- Rédaction de rapports intermédiaires
- Présentations techniques aux partenaires (résultats, choix de modèles, retours métier)

Description des données

Présentation

- 110 260 enregistrements, 136 variables
- 80 qualitatives, 39 quantitatives, 17 datetime
- Valeurs manquantes : **12%**

Sources

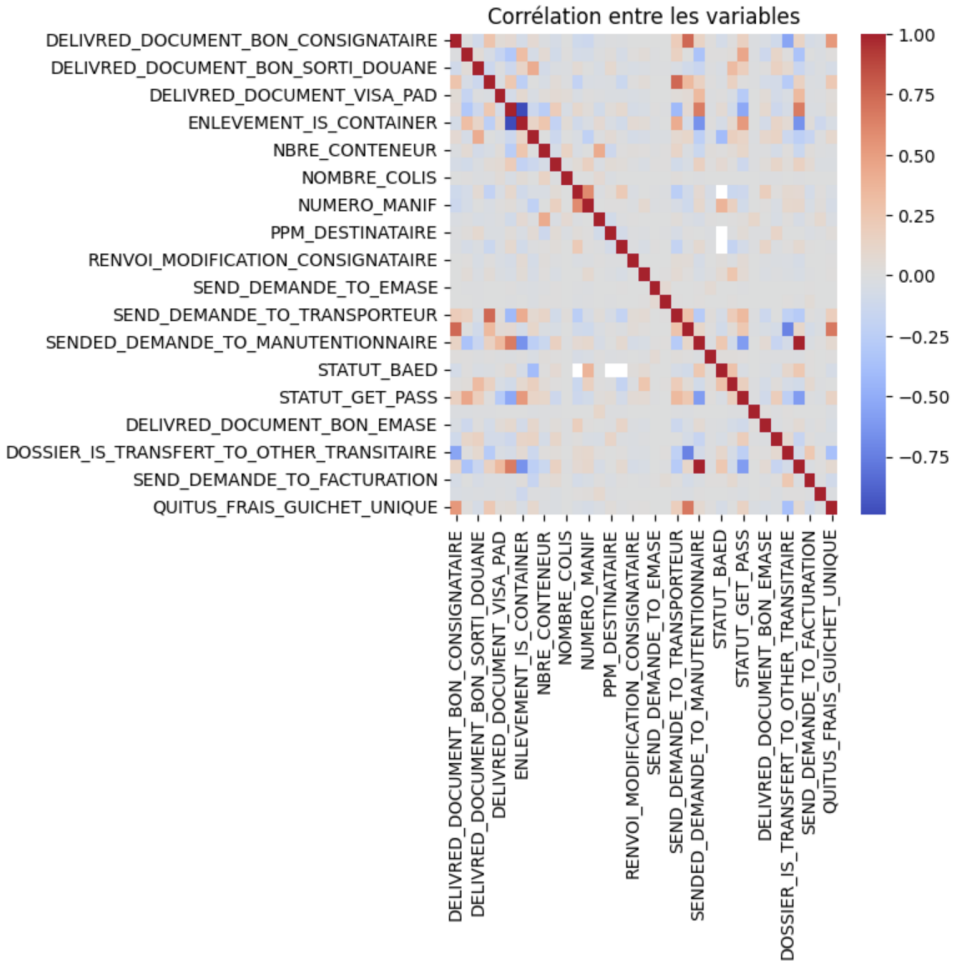
- Données Gaïndé 2000 hébergées sur Oracle Cloud
- Prétraitement via SQL/PLSQL
- Accès sécurisé depuis Jupyter Notebook (Oracle Cloud DS)

Prétraitement des données

- Traitement des valeurs manquantes (**12%**)
- Standardisation des formats (dates, heures, nombres)
- Renommage et sélection des variables pertinentes
- Ingénierie de nouvelles variables dérivées

Analyse exploratoire

- Analyses statistiques pour comprendre structure et distributions
- Détection de corrélations et comportements intéressants
- Sélection des variables adaptées à chaque cas d'usage



Méthode générale

- Définition de la variable cible par cas d'usage
- Sélection des variables explicatives pertinentes
- Split données : 80% train / 20% test
- Validation croisée pour hyperparamètres
- Modèles explorés : logistique, SVM, RF, XGBoost, ARIMA/SARIMA
- Calibration de la probabilités si nécessaire
- Évaluation par F1-score, MAE, RMSE

Cas d'usage 1: Probabilité de succès d'un dossier

Problème

- Prédire si un dossier douanier est **régulier** (sans blocage)
- Objectifs : prioriser les dossiers à risque, réduire délais, optimiser ressources

Random Forest (meilleur compromis)

- Robuste, interprétable (importance des variables)
- Probabilités fiables après calibration
- Score global : **96% F1**

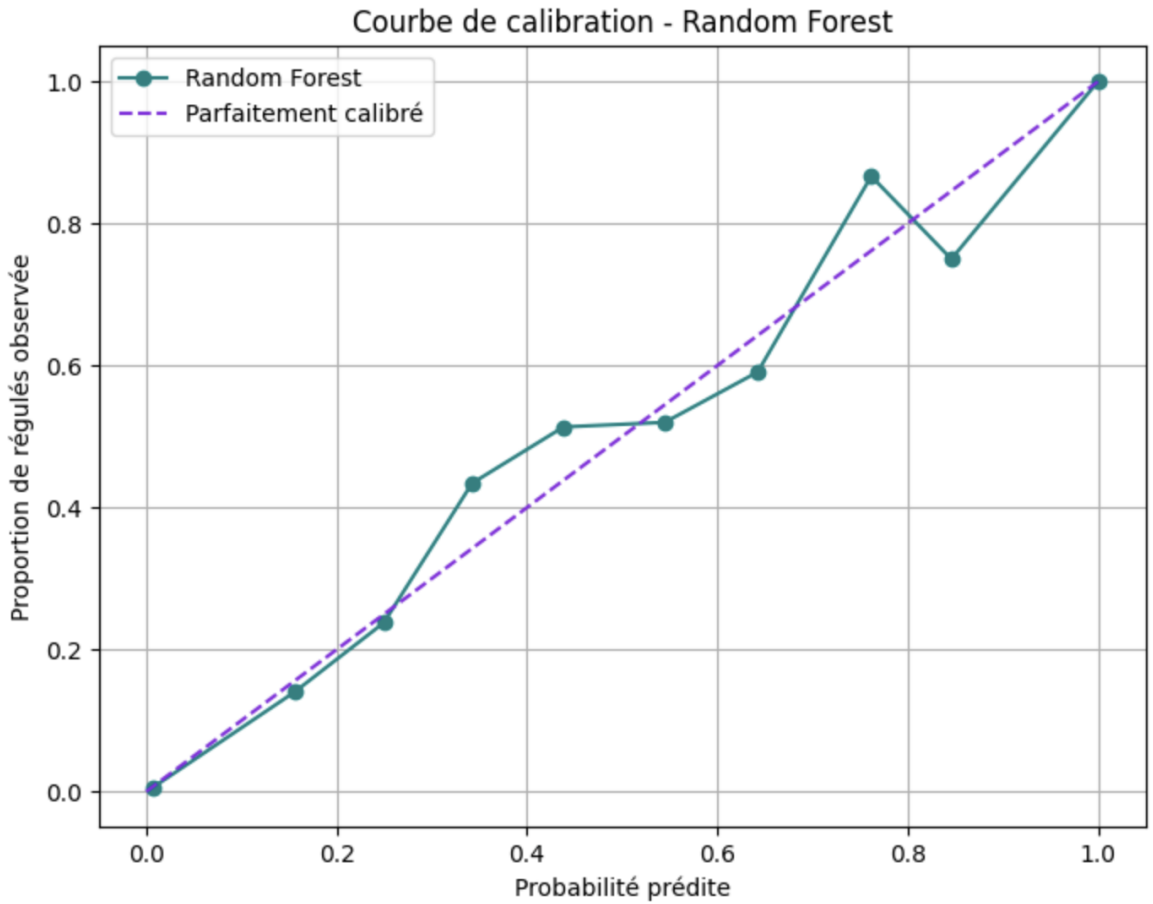
Impact

- Détection précoce des dossiers sensibles
- Fluidification des traitements réguliers
- Allocation optimale des ressources humaines

Résultats et apports

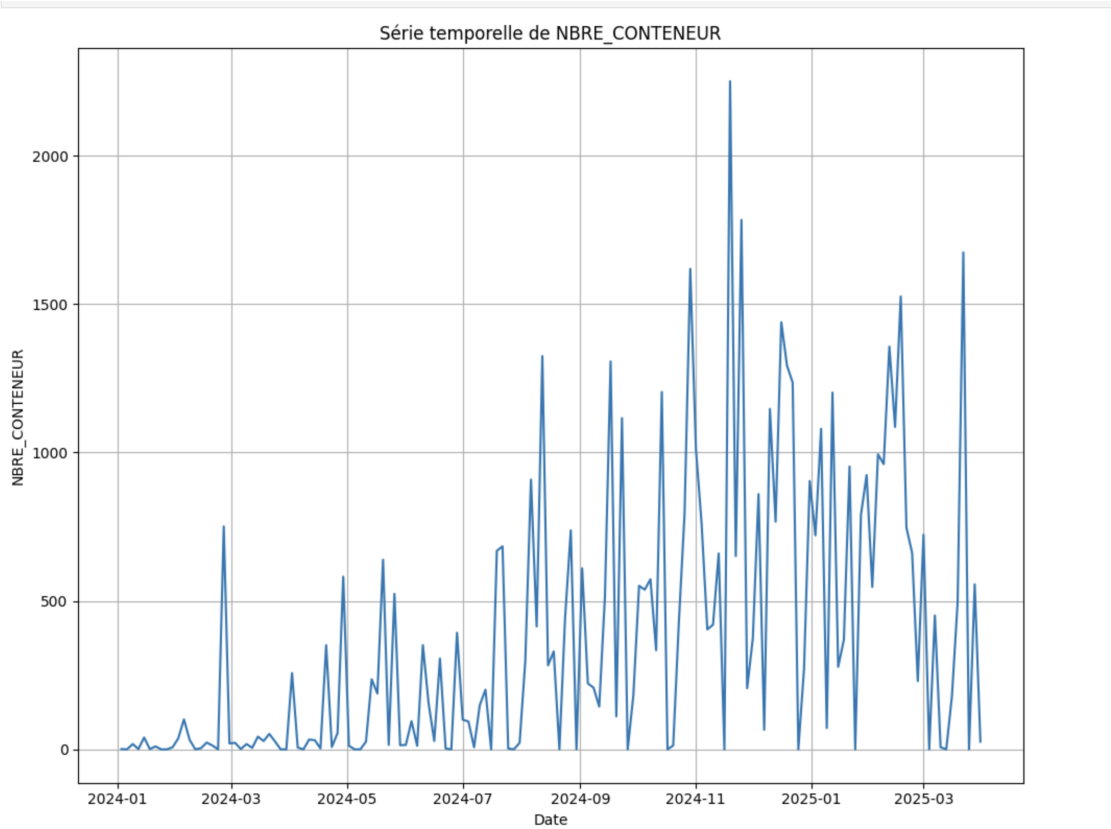
Résultats clés

- Faible risque ($p \geq 0.8$) : 99% régularisés
- Haut risque ($p \leq 0.5$) : 97% bloqués



Les Séries temporelles

Définition Suite d'observations $\{y_t\}$ indexées par le temps.

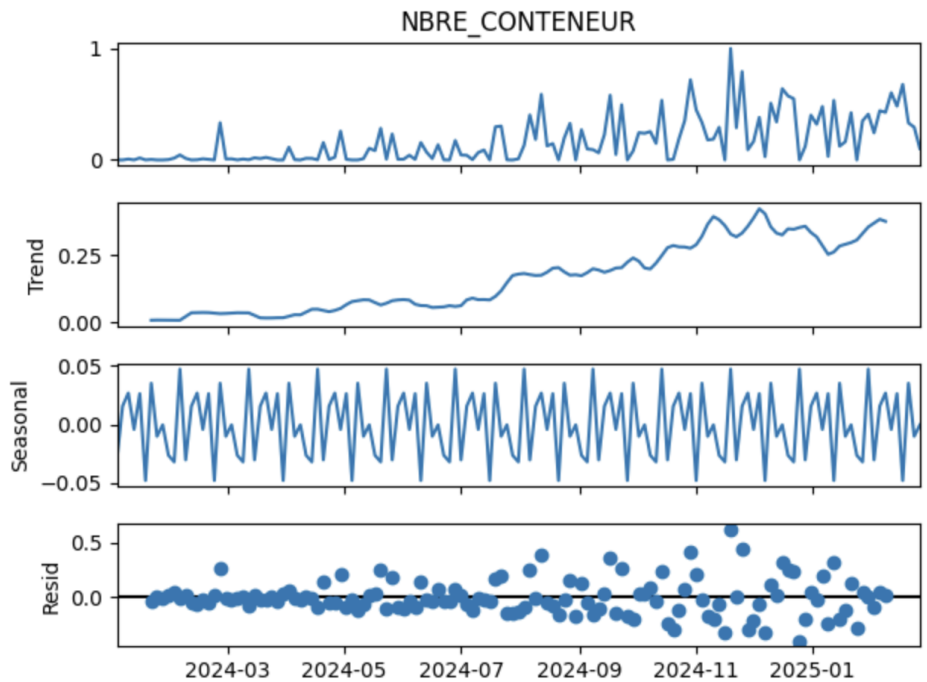


Objectifs

- Modéliser la dynamique du phénomène
- Prédire les valeurs futures
- Comprendre tendance, saisonnalité, bruit

Méthode générale d'analyse

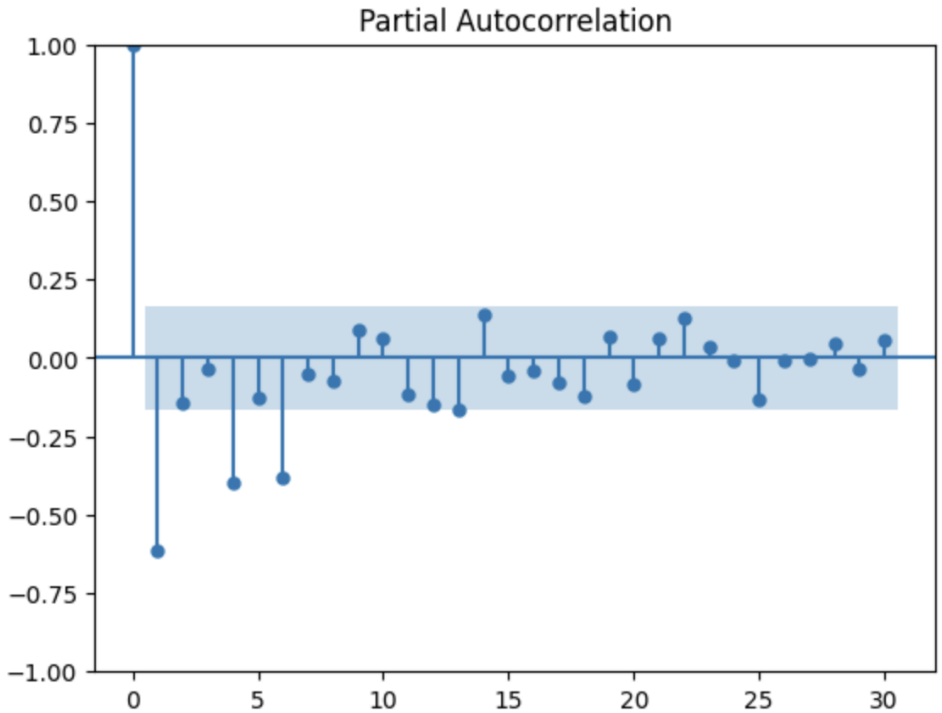
1. **Prétraitement** : valeurs manquantes, outliers, transformation
2. **Décomposition** : tendance, saisonnalité, bruit




```
ADF statistic: -0.6376870220864491
p-value: 0.862236928625642
```

Méthode générale d'analyse

1. **Stationnarité** : tests ADF différenciation si nécessaire
2. **Dépendance** : ACF, PACF pour retards



3. **Choix du modèle** ARMA/ARIMA, SARIMA (saisonnalité)

Méthode générale d'analyse

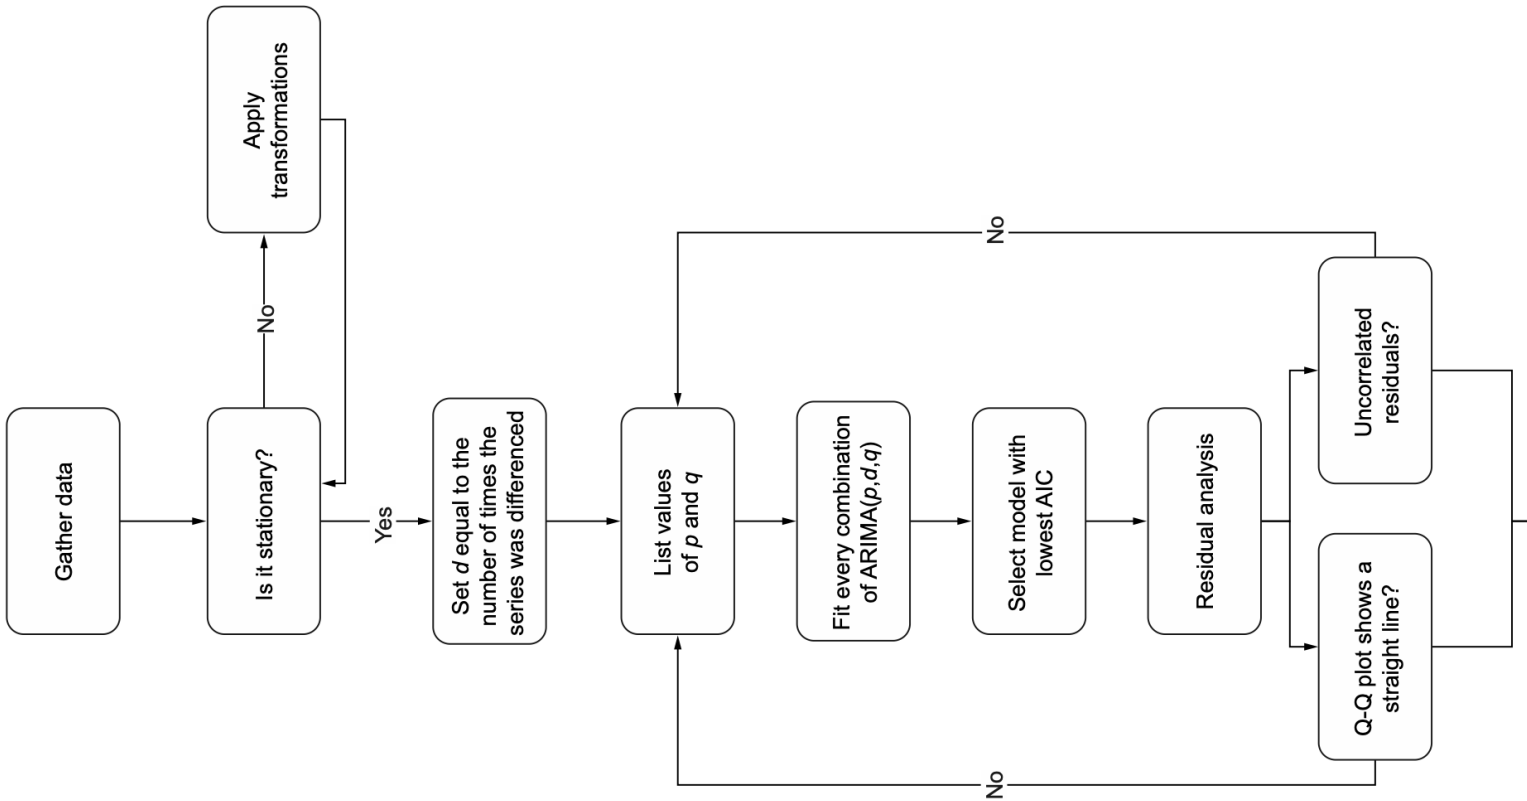


Figure 7.4 General modeling procedure for using the ARIMA(p,d,q) model. Notice the addition of a step where we specify the parameter d for the ARIMA(p,d,q) model. Here, d is simply the minimum number of times a series must be differenced to become stationary.

Cas d'usage 2 : Prévision du volume de marchandise

Objectif : prédire le volume de marchandise colis et conteneurs pour planifier les quais et personnels.

Données

- 328 observations (fenêtres de 3 jours), 4 variables
- Cibles : `NBRE_CONTENEUR`, `NOMBRE_COLIS`, `POIDS_TOTAL`, `NOMBRE_ARTICLE`

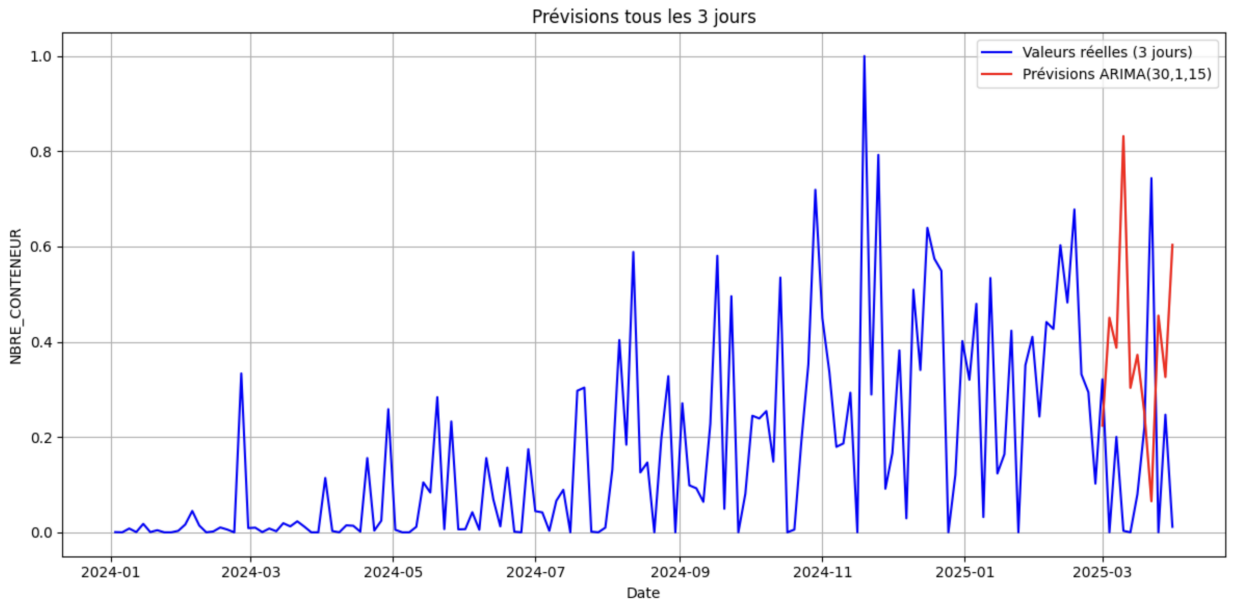
Modélisation et résultats

- **ARIMA(30,1,15)** : MAE = 0.36, mais limites sur pics brusques
- **Random Forest** avec enrichissement des variables :
  - Lags et moyennes mobiles
  - Composantes saisonnières (sin/cos)
  - Indicateurs calendaires (jour, mois, trimestre)

Cas d'usage 2 : Prévision du volume de marchandise

Résultats

- Random Forest : MAE = 0.20
- Suit globalement les tendances
- Limite : manque de données (1 an) $\rightarrow$ prévisions instables



Cas d'usage 3 : Prévision du nombre de dossiers

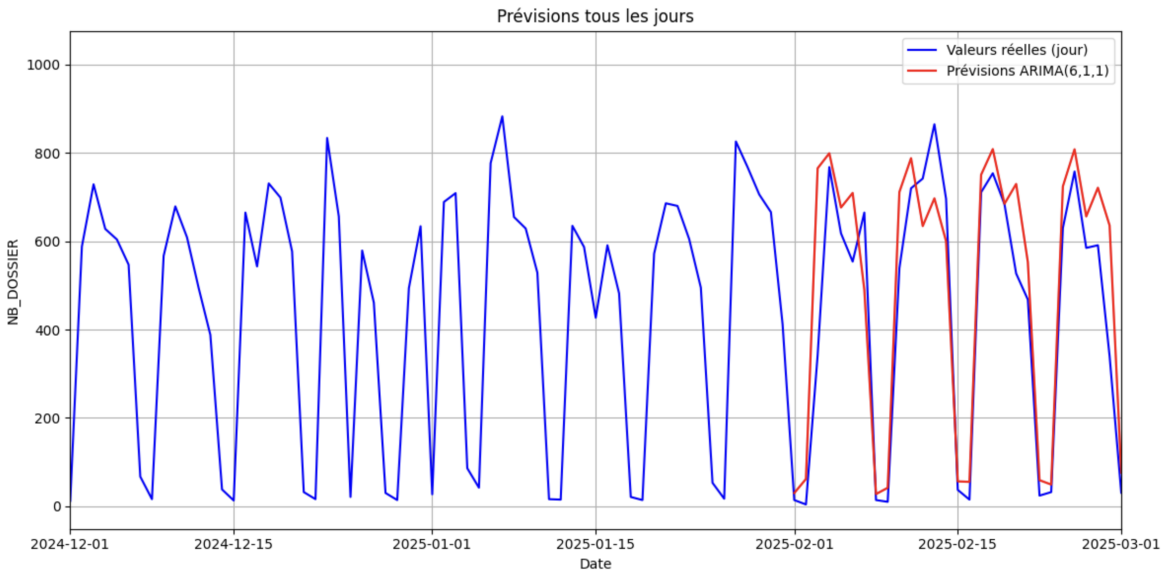
Objectif : prédire le nombre de dossiers journaliers pour optimiser la charge et la gestion des tâches.

Données et analyse

- 455 observations, fréquence journalière

Modèle SARIMA

- SARIMA$(6,1,1)(3,1,4)_7$
- Sélection des ordres via ACF/PACF, tests de stationnarité et AIC
- MAE $= 0.67$



Intégration APEX

- Déploiement via API FastAPI (`/predict`)
- Appel REST avec `APEX_WEB_SERVICE`, parsing JSON avec `APEX_JSON`
- Prévisions accessibles en temps réel dans APEX

Discussion

- **Forces** : exploitation efficace des données, modèles performants (classification et prévision).
- **Limites** : volume de données limité
- **Améliorations** : enrichissement des données, exploration de modèles avancés (LSTM, Prophet), automatisation complète du pipeline.

Conclusion et Perspectives

- L'IA optimise le Port Autonome de Dakar : réduction des délais et des coûts.
- Modèles performants : **Random Forest**, **ARIMA/SARIMA**.
- Perspectives : collecte de données supplémentaires, tableau de bord Oracle APEX, modèles avancés pour séries temporelles, automatisation complète.

Merci pour votre attention !