INFINITY ANALYTICS

Système Intégré d'Analyse de Données Portuaires et Douanières

Rapport du Use Case: DÉTECTION DES DOSSIERS SUSPECTS OU BLOQUANT

Auteur :

Mohammed Nourou Dine Cisse / Bangath Systems

Diffusion :

Modou DIOP / Gainde 2000
Mame Anta DIOP / Gainde 2000
Issa Dieye / RDS
Moustapha SECK / Gainde 2000
Mor Talla DIOP / Gainde 2000
Arona KANE / BS
Mohammed Nourou Dine Cissé / BS

References :

Extraction Orbus Infinity
Infinity Analytics / Modèle de Données
Mohammed Nourou Dine Cissé

Version du document : 1.0
Date : 01/07/2025

Description du problème..... 3
Choix des méthodes..... 3
Exploration des données (EDA)..... 3
Modélisation et évaluation..... 4
Critères de comparaison..... 5
Résultats clés..... 5
Résultats..... 5
Courbe d’apprentissage:..... 5
Performances détaillées..... 6
Rapport de classification (Random Forest)..... 6
Matrice de confusion..... 7
Conclusion..... 7

Description du problème

Chaque jour, les services douaniers traitent des dizaines de milliers de déclarations. Certaines de ces déclarations présentent des irrégularités : informations manquantes, documents incorrects, frais non réglés... Ces anomalies génèrent des retards, des coûts supplémentaires et des litiges.

Objectif : mettre en place un outil capable de signaler, **en amont**, les dossiers à haut risque de blocage ou de retour, afin de :

- Intervenir proactivement sur les anomalies
- Réduire les délais de dédouanement
- Limiter les frais supplémentaires et les litiges

Choix des méthodes

Puisque notre base contient plus de 110 000 dossiers labellisés (`bloqué` vs `régulier`), nous avons comparé plusieurs approches d'apprentissage supervisé :

- **Régression logistique**, pour ses coefficients explicites et sa simplicité
- **Random Forest**, pour sa robustesse face au bruit et aux variables corrélées
- **XGBoost** et **LightGBM**, réputés pour leur rapidité et leur gestion fine des hyperparamètres

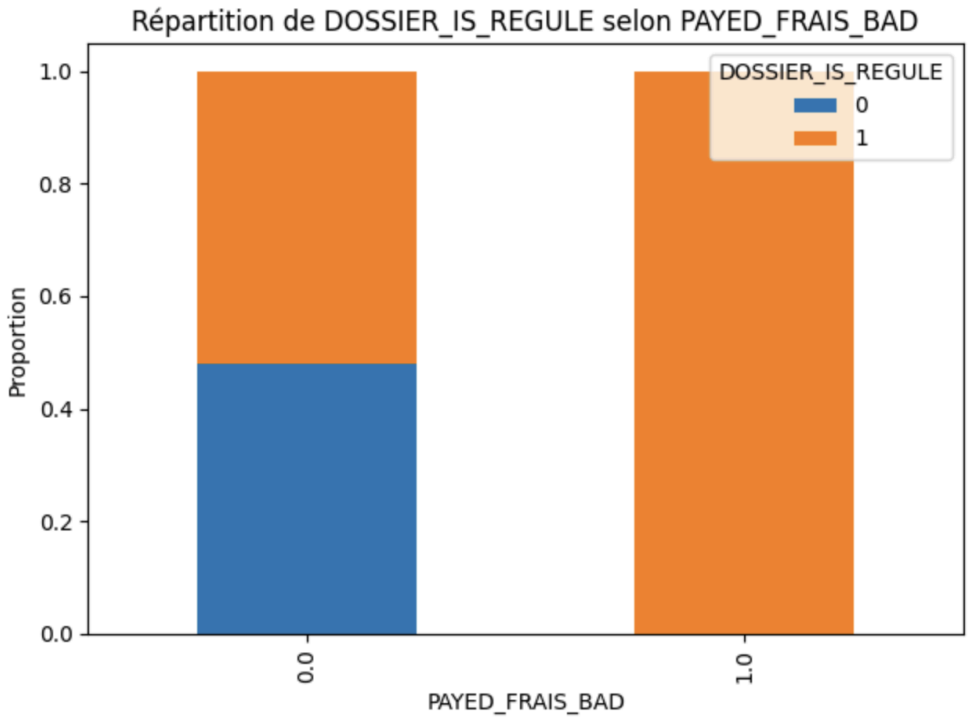
Chaque algorithme a été calibré (validation croisée, techniques de recalibrage) pour maximiser à la fois la détection des vrais dossiers bloqués (rappel) et la limitation des faux positifs (précision).

Exploration des données (EDA)

1. **Volume et structure**
    - **110 000** dossiers
    - **Variables** : dates (demandes, envoi...), indicateurs booléens (documents fournis), quantitatifs (poids, nombre d'articles, frais)
2. **Nettoyage**
    - Suppression des colonnes inutiles
    - Conversion des True/False en 0/1

3. **Insight initial**
    - Certains indicateurs (absence de justificatif, frais non réglés) apparaissent nettement plus fréquents dans les dossiers regulé.

Exemple:



Modélisation et évaluation

Après prétraitement et encodage, nous avons testé plusieurs modèles :

- **Random Forest**
- **XGBoost**
- **LightGBM**

Critères de comparaison

- **Précision globale**
- **Rappel** sur la classe « bloqué » (vrais rappels)
- **Taux de faux positifs** (pour ne pas encombrer inutilement les équipes)
- **Temps d'entraînement** et de prédiction

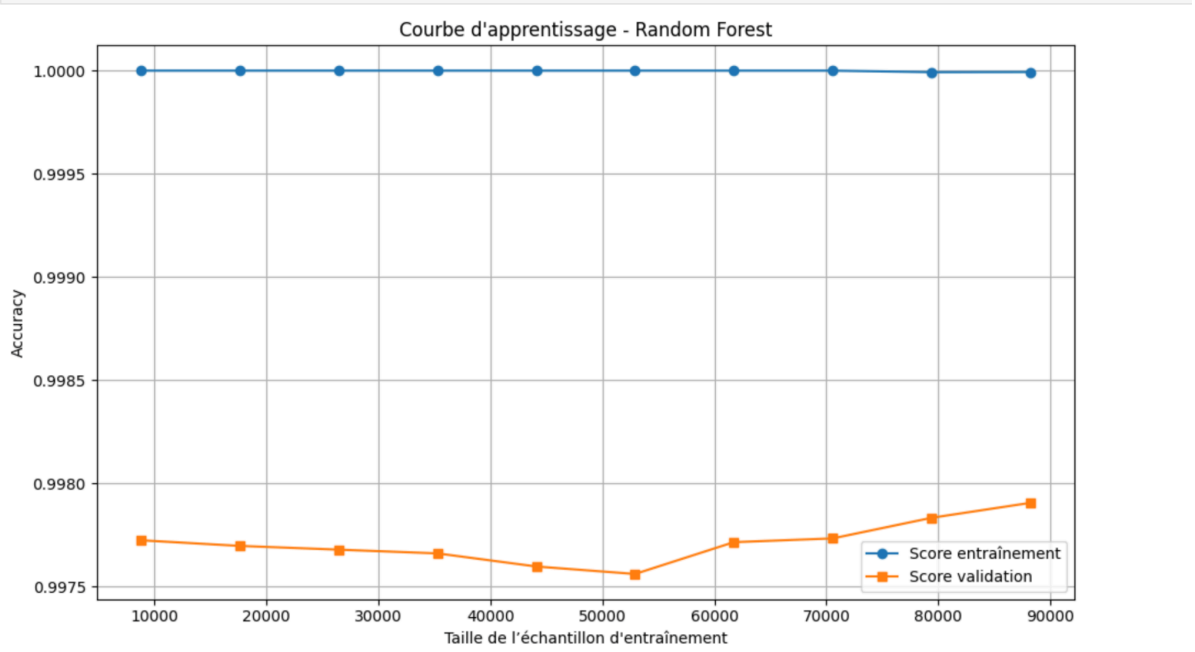
Résultats clés

Modèle	Précision globale	Rappel (bloqué)	Faux positifs	Temps d'entraînement
Random Forest	99,8 %	97,2 %	Faible	Rapide
XGBoost	99,7 %	96,8 %	Modéré	Modéré
LightGBM	99,6 %	96,5 %	Modéré	Très rapide

Choix retenu : Random Forest
Raison : meilleure détection des dossiers bloqués (97,2 % de rappel) tout en conservant une précision globale très élevée (99,8 %) et un temps d'exécution satisfaisant.

Résultats

Courbe d'apprentissage:



Le modèle révèle une performance optimale : sur les données d'entraînement, la courbe d'apprentissage atteint la note maximale (1), tandis que sur le jeu de test elle se situe très proche du parfait, entre 0,98 et 1, attestant d'une excellente généralisation sans surapprentissage.

Le modèle apprend parfaitement les tendances présentes dans les données d'entraînement (aucune erreur de biais)

Il généralise très bien aux nouvelles observations, puisque la performance sur le test est quasi identique à celle sur l'entraînement

Il n'y a pas de surapprentissage significatif, car on ne constate pas d'écart marqué entre train et test (écart < 0,02)

La variance du modèle est faible, ce qui signifie que ses prédictions sont stables et fiables quels que soient les échantillons

Le compromis biais-variance est idéal, assurant à la fois précision et robustesse

Performances détaillées

Rapport de classification (Random Forest)

Classe	Précision	Rappel	F1-score	Support
Bloqué (0)	0.97	0.97	0.97	1000
Régularisé (1)	0.99	0.99	0.99	21048

Matrice de confusion

	Prédit = Bloqué	**Prédit = Régularisé**
Réel = Bloqué	97,2 %	2,8 %
Réel = Régularisé	0,1 %	99,9 %

La matrice de confusion montre que le modèle ne se trompe que sur 0.1 % pour les dossiers régularisés et 2.8% pour les dossiers non régularisés.

Conclusion

En somme, le modèle déployé pour le Use Case 2 s'avère d'une fiabilité remarquable :

- **Précision globale de 99,8 %** avec un taux d'erreur de seulement 0,1 % sur les dossiers régularisés et 2,8 % sur les dossiers bloqués
- **Excellente capacité de généralisation**, attestée par la proximité des courbes d'apprentissage train et test
- **Probabilités bien calibrées**, permettant de définir des seuils opérationnels clairs pour le déclenchement automatique des contrôles

Concrètement, cet outil offre aux équipes douanières :

1. **Une détection presque exhaustive** des dossiers à risque,
2. **Une réduction significative** des retards et des coûts liés aux dossiers bloqués,
3. **Une allocation optimisée** des ressources, en concentrant l'effort sur les vrais cas problématiques.

En production, il constituera un pilier de la transformation digitale des procédures douanières, alliant performance, transparence et agilité.