INFINITY ANALYTICS

Système Intégré d'Analyse de Données Portuaires et Douanières

Rapport du Use Case:
ESTIMATION DE LA PROBABILITÉ DE SUCCÈS D'UN DOSSIER

Auteur :

Mohammed Nourou Dine Cisse / Bangath Systems

Diffusion :

Modou DIOP / Gainde 2000
Mame Anta DIOP / Gainde 2000
Issa Dieye / RDS
Moustapha SECK / Gainde 2000
Mor Talla DIOP / Gainde 2000
Arona KANE / BS
Mohammed Nourou Dine Cissé / BS

References :

Extraction Orbus Infinity
Infinity Analytics / Modèle de Données
Mohammed Nourou Dine Cissé

Version du document : 1.0
Date : 01/07/2025

Description du problème **3**
Choix des méthodes **3**
Exploration des données (EDA) **3**
Modélisation et évaluation **4**
Résultats **5**
Rapport de classification **5**

Description du problème

Développer un système intelligent capable d'estimer la probabilité que chaque déclaration douanière soit traitée sans blocage ni retour pour correction.

Certains dossiers passent sans encombre, d'autres sont bloqués par des pièces manquantes ou des informations erronées, entraînant retards et coûts supplémentaires. Notre objectif est de prédire, pour chaque dossier, la probabilité qu'il soit « régulier » (traité sans blocage) afin de :

- Mettre en avant ceux qui nécessitent une attention urgente
- Éviter que des dossiers à fort risque stagnent inutilement
- Allouer efficacement les agents et les ressources

Cette vision préventive permet de fluidifier le processus et d'optimiser les délais.

Choix des méthodes

Nous disposons d'un historique labellisé (`DOSSIER_IS_REGULE` = 0 ou 1), ce qui nous oriente naturellement vers l'apprentissage supervisé. Pour trouver le meilleur compromis précision/rapidité/calibration, nous avons considéré :

- Régression logistique, pour sa simplicité et sa transparence
- Support Vector Machine (SVM), pour modéliser des frontières de décision complexes
- Random Forest, robuste face au bruit
- XGBoost et LightGBM, performants sur de grands jeux de données

Chaque algorithme sera calibré (Platt, isotonic…) pour que ses probabilités reflètent au plus juste les fréquences réelles.

Exploration des données (EDA)

Avant tout, il a fallu comprendre le jeu de données :

- Volume : 110 260 dossiers
- Variables : 33 au total
    - 39 quantifiables (poids, nombre d'articles, délai de traitement…)
    - 80 booléennes (présence de documents, statuts divers)
    - 17 temporelles (dates de soumission, de validation…)
- Valeurs manquantes : ~12 %

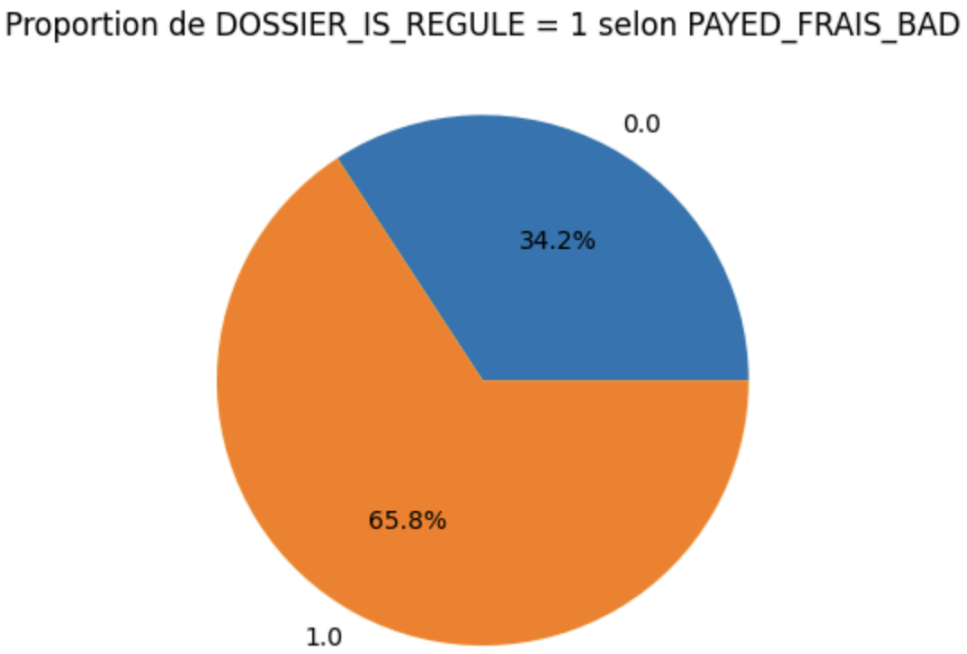
- Variable cible : `DOSSIER_IS_REGULE` (0 = bloqué, 1 = régularisé)

Le nettoyage a consisté à :

1. Supprimer les colonnes constantes
2. Uniformiser les formats de date et de nombre
3. Transformer chaque document/statut en indicateur 0/1

Distribution d'une variable selon la cible

Pour illustrer le pouvoir discriminant, nous avons tracé la distribution du PAYED_FRAI_BAD :



On s'attend à voir que les dossiers réguliers paient la plus part du temps les frais BAD, ce qui confirme l'intérêt de cette variable.

Modélisation et évaluation

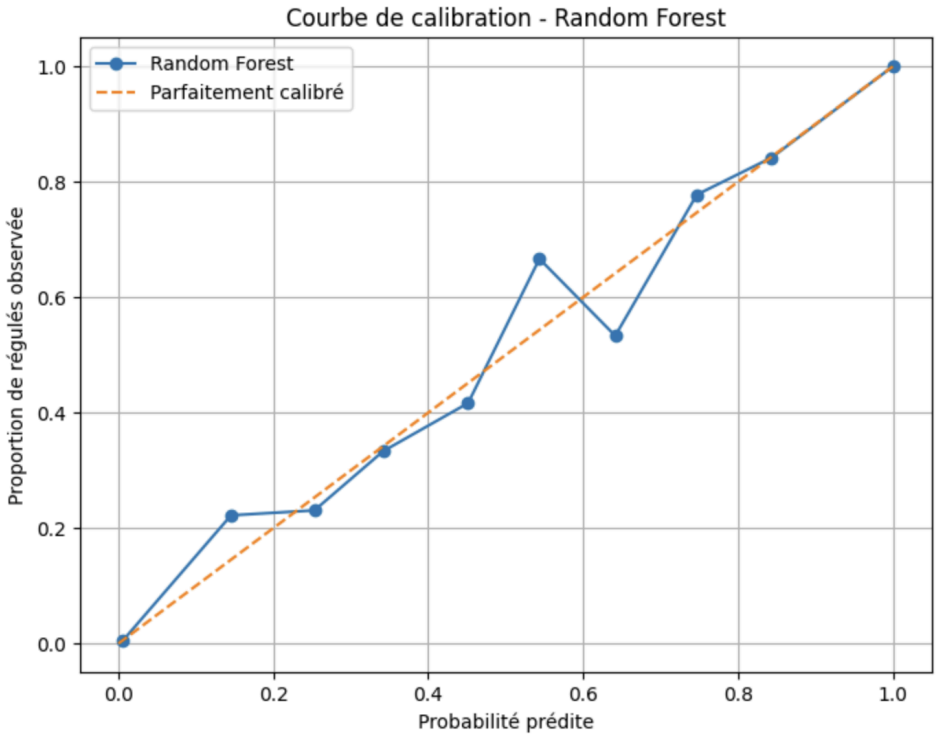
1. Séparation : 80 % des données pour l'entraînement, 20 % pour le test
2. Validation croisée : réglage des hyperparamètres (nombre d'arbres, profondeur, régularisation…)
3. Calibration : aligner les probabilités prédites sur les fréquences observées

Parmi tous les modèles, la Random Forest s'est distinguée par :

- Sa rapidité de calcul
- Sa robustesse face au bruit
- Des probabilités fiables après calibration

Résultats

Courbe de représentation de la probabilité prédite et de la proportion réelle.



Résumé de la calibration et des niveaux de risque :

Sur l'échantillon de test, on obtient les résultats suivants :

- **Dossiers à faible risque (proba ≥ 80 %)**
  Parmi les dossiers pour lesquels le modèle prédit une probabilité de succès d'au moins 80 %, **99 %** sont effectivement régularisés.
- **Dossiers à haut risque (proba ≤ 50 %)**
  Parmi ceux pour lesquels la probabilité prédite est de 50 % ou moins, **97 %** se révèlent finalement bloqués (non régularisés).

Ces chiffres confirment que nos seuils de 80 % et 50 % permettent de bien distinguer les dossiers presque sûrs de ceux à risque élevé.

- La **courbe de calibration** (à insérer) confirmera l'alignement des probabilités prédites avec les fréquences réelles, garantissant qu'on peut se fier aux prédictions extrêmes et ajuster les seuils si besoin selon le niveau de tolérance au risque.

Rapport de classification

Voici le rapport de classification mis en forme dans un tableau :

La précision globale atteint 99,8 %, avec un très faible taux de faux positifs et de faux négatifs.

Classe	Précision	Rappel	F1-score	Support
Bloqué (0)	0.97	0.97	0.97	1000
Régularisé (1)	0.99	0.99	0.99	21048

Conclusion

En résumé, nous avons développé un modèle supervisé robuste et bien calibré, capable de fournir pour chaque dossier une probabilité de succès exploitable. Grâce à des explorations poussées des données, au choix d'algorithmes performants (Random Forest) et à une calibration rigoureuse, notre outil distingue clairement :

- Les dossiers à très haut risque (≤ 50 % de probabilité), qui nécessitent une intervention manuelle immédiate (97 % de blocs réellement constatés) ;
- Les dossiers à très faible risque (≥ 80 % de probabilité), qui peuvent suivre un traitement normal sans contrôle supplémentaire (99 % de succès réellement constatés) ;
- Les dossiers intermédiaires, qui requièrent un suivi et éventuellement une deuxième vérification si leur probabilité évolue.

Ce système offre aux services douaniers une visibilité fine sur le niveau de risque de chaque dossier, permettant de prioriser efficacement les ressources, de réduire les retards et d'améliorer la qualité de service. L'intégration en temps réel et l'enrichissement futur avec des données non structurées promettent de renforcer encore l'efficacité et la précision de cette solution.