Présentation du Dataset : New York City Airbnb Open Data

Analyse Exploratoire et Segmentation (2019)

Marc-Antony Tchicou Kelvin Wong Mouhamed Cisse Alexis Schneider Mohammed-Yahya Dami

Novembre 2025

1 Contexte et Origine des Données

Depuis 2008, Airbnb transforme la manière dont les logements touristiques sont proposés et consommés. Le dataset public **NYC Airbnb Open Data (2019)** contient environ **49 000 annonces**. Chaque ligne correspond à un logement actif à New York en 2019.

Le fichier comporte **16 variables**, réparties entre :
— données géographiques,
— caractéristiques du logement,
— informations sur l'hôte,
— indicateurs d'activité et de professionnalisation.

2 Description des Variables

Au-delà du tableau synthétique, il est important de préciser le rôle réel de chaque catégorie de variables dans notre analyse.

Variables d'identification. Elles permettent d'identifier les annonces et les hôtes. `id` et `host_id` sont essentiels pour repérer les multi-propriétaires, tandis que `name`, `host_name` et `last_review` ont une utilité contextuelle mais ne sont pas exploitées dans les modèles.

Variables géographiques. Elles structurent l'analyse spatiale. `neighbourhood_group` renseigne l'arrondissement, `neighbourhood` affine l'analyse à l'échelle locale, et les coordonnées GPS permettent le clustering spatial (DBSCAN) pour détecter les zones touristiques réelles.

Variables décrivant le logement. `room_type` influe fortement sur le prix et le type d'usage (économie de partage vs location entière). `price` est une variable centrale mais bruitée, nécessitant un nettoyage. `minimum_nights` identifie des usages para-hôteliers (séjours minimum longs).

Variables d'activité et de professionnalisation. Elles mesurent l'intensité d'usage. `number_of_reviews` et `reviews_per_month` indiquent l'activité réelle, `availability_365` reflète l'usage professionnel potentiel, et `calculated_host_listings_count` est la variable clé pour repérer les multi-propriétaires.

Variable	Catégorie	Description
1. Identification		
id	Identifiant	Identifiant unique de l'annonce.
name	Métadonnée	Titre public de l'annonce.
host_id	Identifiant	Identifie les hôtes possédant plusieurs annonces.
host_name	Métadonnée	Nom public de l'hôte.
last_review	Date	Date du dernier commentaire reçu.
2. Géographie		
neighbourhood_group	Catégorielle	Arrondissement (Manhattan, Brooklyn, Queens...).
neighbourhood	Catégorielle	Quartier précis.
latitude	Coordonnée	Latitude géographique du logement.
longitude	Coordonnée	Longitude géographique du logement.
3. Caractéristiques du logement		
room_type	Catégorielle	Entire home, Private room, Shared room.
price	Numérique	Prix par nuit (USD).
minimum_nights	Numérique	Durée minimale du séjour requise.
4. Activité et professionnalisation		
number_of_reviews	Numérique	Total d'avis reçus.
reviews_per_month	Numérique	Fréquence mensuelle d'avis.
calculated_host_listings_count	Numérique	Nombre total d'annonces gérées par l'hôte.
availability_365	Numérique	Nombre de jours disponibles par an.

3 Problématique et Objectifs du Projet

3.1 Problématique

Airbnb se présente comme une plateforme d'économie de partage, où des particuliers louent ponctuellement leur logement. Pourtant, l'analyse des données révèle l'existence d'hôtes multi-propriétaires et de logements disponibles toute l'année, laissant supposer une professionnalisation importante du marché.

La question centrale du projet est donc :

Dans quelle mesure le marché Airbnb new-yorkais reflète-t-il encore une économie de partage, et comment l'activité des hôtes (occasionnels, multi-propriétaires, opérateurs quasi-hôteliers) se structure-t-elle à travers la géographie et les comportements d'usage ?

L'objectif est double : (1) dépasser les frontières administratives pour révéler les zones touristiques réelles, (2) identifier des segments de marché révélant la structure économique du marché Airbnb.

3.2 Approche Méthodologique

Notre démarche suit un pipeline rigoureux, enrichi par des règles métiers permettant de détecter les comportements para-hôteliers.

1. **Préparation et nettoyage** Traitement des valeurs manquantes, suppression des outliers de prix, transformation du prix en `log_price`, et création d'un `host_profile` basé sur :
   — nombre d'annonces $> 2 \Rightarrow$ multi-propriétaire,
   — disponibilité > 180 jours $\Rightarrow$ usage potentiellement commercial.
2. **Réduction de dimension (ACP)** L'ACP révèle deux axes majeurs : l'intensité commerciale (reviews, listings, disponibilité), les caractéristiques de séjour (prix, minimum nights).
3. **Clustering comportemental (K-Means)** Identification de quatre profils d'annonces : hôtes occasionnels, annonces haut de gamme, multi-propriétaires, opérateurs quasi-hôteliers.
4. **Clustering spatial (DBSCAN)** Détection des zones touristiques réelles via les coordonnées GPS, montrant un « super-cluster » reliant Manhattan à Brooklyn.